



Retraso Logístico

Predicción de Demoras con Machine Learning

Dataset: retraso_logistica.csv | Herramienta: Orange Data Mining

Grupo Data Rose

Valentina Montechi, Pilar Ospital, Emilia Rizzato, Felicitas Lacentre y Chiara Behar

Problema de Negocio

¿Por qué predecir retrasos?

Situación actual

Los retrasos se detectan de forma **reactiva** — el cliente ya sufrió el problema.

Consecuencias:

- Pérdida de credibilidad
- Costos de compensación al cliente
- Daño reputacional acumulado

Variable Target

entrega_demorada

1 = Demorado 0 = A tiempo

Métrica Prioritaria: Recall

Falso Negativo (más costoso): predecir 'a tiempo' cuando llega tarde
→ cliente insatisfecho + compensaciones



Variables del Dataset

Variables numéricas

Variable	Tipo	Descripción
peso_paquete_kg	Numérica continua	Peso físico del paquete (admite decimales)
volumen_paquete	Numérica continua	Tamaño de la caja en cm ³
distancia_km	Numérica continua	Km entre almacén de origen y destino final
intentos_previos	Numérica entera	Visitas a domicilio fallidas acumuladas
valor_declarado_ars	Numérica continua	Costo del producto asegurado (en ARS)



Variables del Dataset

Variables categóricas

fecha_despacho	Fecha/hora de salida del centro de distribución
codigo_postal_dest	Código Postal Argentino del destino
provincia_destino	Provincia de Argentina para la entrega
categoria_producto	Rubro o sector del artículo comprado
proveedor_logistico	Empresa transportista asignada (Andreani, OCA, Correo Arg., Transp. Propio)
clima_despacho	Pronóstico meteorológico al día de despacho (Despejado / Lluvia / Tormenta)
es_vispera_feriado	Si el día siguiente o subsiguiente es feriado nacional (Sí / No)
tipo_envio	Modalidad de entrega contratada (Normal / Express / Same-Day)
etiqueta_fragil	Si el paquete requiere manipulación especial durante traslado



Análisis Exploratorio de Datos

EDA — 7 Hipótesis analizadas en Orange

H1 Distancia

H2 Clima

H3 Tipo Envío

H4 Intentos Previos

H5 Proveedor

H6 Feriado

H7 Peso

Widgets usados: Distributions · Box Plot · Mosaic Display · Data Table

Objetivo: identificar qué variables tienen poder predictivo real antes de modelar.

H1 — Distancia del Envío

A mayor distancia, mayor probabilidad de demora

Media A Tiempo

1.201 km

Q1: 562 km | Mediana: 1.163 km

Media Demorados

1.462 km


Q1: 1.050 km | Mediana: 1.524 km

Diferencia Media

+261 km

entre grupo demorado y a tiempo

Box Plot — distancia_km



Conclusión

Variable recomendada


Hay solapamiento entre distribuciones, por lo que la distancia sola no predice el retraso. Se creó 'Tipo Distancia' para capturar el efecto de forma no lineal.

H2 — Clima al Momento del Despacho




El clima adverso aumenta la tasa de demora

Tormenta = 45% de demora vs ~17–18% en condiciones normales (casi el TRIPLE). La lluvia por sí sola NO genera demoras adicionales. La tormenta es predictor fuerte e independiente.




Despejado

tasa de demora



Lluvia

tasa de demora



Tormenta


tasa de demora

H3 · H4 · H5 — Variables sin Poder Predictivo

Los tres graficos muestran distribuciones casi identicas entre grupos -> variables descartadas del modelo

H3 — Tipo de Envio


tipo_envio vs entrega_demorada



p ~ 20% en los 3 tipos. Sin poder predictivo.

H4 — Intentos Previos


intentos_previos vs entrega_demorada



T - Student = 0.497, p = 0.619. Sin diferencia significativa.

H5 — Proveedor Logistico

proveedor_logistico vs demora



Todos los proveedores ~20% demora. Sin diferencia.

H3 · H4 · H5 — Variables sin Poder Predictivo

H3 — Tipo de Envío

Express, Normal y Same-Day muestran ~20% de demoras cada uno. Las barras son visualmente indistinguibles.

No incluir en el modelo

H4 — Intentos Previos

Media A tiempo: 1,49 +/-1,1 | Media Demorado: 1,51 +/-1,1
Student's t = 0,497 -> p = 0,619 (> 0,05)

No incluir en el modelo

H5 — Proveedor Logístico

Mosaic Display: Andreani, OCA, Correo Argentino y Transporte Propio muestran tasas de demora casi idénticas.

No incluir en el modelo



H6 — Víspera de Feriado

*Los pedidos despachados en víspera de feriado se demoran más
La variable MÁS predictora identificada en todo el EDA*

No es víspera
de feriado

~18%

tasa de demora

Sí es víspera
de feriado

~41%

tasa de demora — MÁS DEL DOBLE



Despachar en víspera de feriado aumenta drásticamente el riesgo de demora → suponemos que hay sobrecarga operativa en los centros de distribución. Se incluye como prioridad en el modelo.



H7 — Peso del Paquete

Los paquetes más pesados llegan más tarde

A tiempo

25,10 kg

$\pm 14,40$ | IQR: 12,73 – 37,51

Demorado

25,27 kg


$\pm 14,27$ | IQR: 12,69 – 37,66

Student's t

p = 0,649

N=10.000 | t = 0,455 (>> 0,05)

Box Plot — peso_paquete_kg (distribuciones casi idénticas)



Conclusión

Variable descartada

Con $p = 0,649$ no hay evidencia estadística. Contrario a lo esperado, el peso no predice la demora.

Resumen del EDA — ¿Qué entra al modelo?

H1	distancia_km	Via 'Tipo Distancia' (binaria)	✓ Incluir
H2	clima_despacho	Tormenta = predictor clave	✓ Incluir
H6	es_vispera_feriado	Variable más predictora (41% vs 18%)	✓ Incluir
H3	tipo_envio	Tasas idénticas (~20%) en todos los tipos	✗ Excluir
H4	intentos_previos	p = 0,619 (sin significancia estadística)	✗ Excluir
H5	proveedor_logistico	Sin diferencia entre proveedores	✗ Excluir
H7	peso_paquete_kg	p = 0,649 (sin significancia estadística)	✗ Excluir

Aspectos Clave de Limpieza y Transformación



1

Limpieza en Google Colab (Pandas)

valor_declarado_ars tenía símbolos monetarios (ARS, \$, espacios). Se eliminaron y se convirtió a numérico antes de cargar en Orange.

3

Tratamiento de valores nulos

Numéricas continuas → reemplazadas por la media (distancia_km, peso_paquete_kg).
Categorías → reemplazadas por la moda.

2

Python Script en Orange

Conversión de tipos incorrectos (fechas como texto) · Corrección de códigos postales incompletos.

4

Detección de Outliers (Isolation Forest)

Se detectó el 10% más atípico con Isolation Forest. El flujo se bifurcó en Inliers (datos limpios) y Outliers. Solo los Inliers continúan al modelado.



Continuize y One-Hot Encoding

Transformación de variables categóricas a numéricas

¿Qué es Continuize?

El widget Continuize de Orange convierte variables categóricas a formato numérico para que los modelos de clasificación puedan procesarlas.

Se aplicó One-Hot Encoding: cada categoría distinta de una variable se convierte en una columna binaria (0 o 1).

¿Por qué es necesario?

Los modelos requieren que las categorías estén representadas en un formato que puedan procesar numéricamente.

Ejemplo: clima_despacho

clima_despacho	Despejado	Lluvia	Tormenta
Despejado	1	0	0
Lluvia	0	1	0
Tormenta	0	0	1

Variables incluidas en el modelo final:

- clima_despacho = Despejado / Lluvia / Tormenta
- es_vispera_feriado = Sí / No



Variable Creada: Tipo Distancia

Feature Engineering mediante widget Fórmula en Orange

Fórmula: `tipo_distancia = 1 si distancia_km > 1300 | 0 si distancia_km ≤ 1300`

0 → Distancia Corta

≤ 1300 km

Mediana a tiempo: 1.163 km

1 → Distancia Larga

> 1300 km

Mediana demorados: 1.524 km



¿Por qué 1300 km?

No es arbitrario: El umbral de 1300 km representa aproximadamente la mediana global del dataset, situándose entre la mediana del grupo a tiempo (1.163 km) y la mediana del grupo demorado (1.524 km).

Creación de Datos Sintéticos

Balanceo de clases para mejorar la calidad del modelo

65%

Clase mayoritaria
(A tiempo)

35%

Clase minoritaria
(Demorado)

4.001

Instancias demoradas

¿Por qué balancear?

El dataset presentaba un fuerte desbalance: muchos más casos "a tiempo" (7431) que demorados (1569). Un modelo entrenado con datos desbalanceados tiende a predecir siempre la clase mayoritaria, ignorando los retrasos (exactamente lo que buscamos evitar).

Método de generación

- Se toman 2 registros al azar de la clase minoritaria.
- Variables numéricas: interpolación ponderada con alpha aleatorio.
- Variables categóricas: se toma al azar uno de los dos valores.
- Se agrega columna 'origen': original / sintético para trazabilidad.

División Train / Test — 80% / 20%

Separación de datos para entrenamiento y evaluación con Data Sampler (Orange)

80% — TRAINING

20% — TEST

¿Qué hace el Training?

El 80% de los datos se usa para que los modelos **aprendan los patrones** que diferencian una entrega demorada de una a tiempo. Los tres algoritmos (Regresión Logística, Random Forest y Naive Bayes) se entrenan sobre este conjunto.

¿Qué hace el Test?

El 20% restante — datos que el modelo **nunca vio durante el entrenamiento** — se usa para medir cómo rinde en situaciones reales.

Los 3 Modelos de Clasificación

¿Qué hace cada modelo para decidir si un envío llega tarde o a tiempo?



Regresión Logística

Como una balanza

Suma el "peso" de cada factor de riesgo y calcula una probabilidad. Si hay tormenta, suma puntos de riesgo. Si es víspera de feriado, suma más. Al final decide: ¿supera el umbral de riesgo?

✓ Se puede explicar fácilmente al negocio: cada variable tiene un peso visible.



Random Forest

Como preguntar a 100 expertos

Construye cientos de árboles de decisión, cada uno entrenado con datos distintos. Cada árbol vota "demorado" o "a tiempo". Gana la opción con más votos.

✓ Detecta combinaciones complejas de variables que una sola regla no captura.



Naive Bayes

Como calcular probabilidades por separado

Estima qué tan probable es la demora analizando cada variable de forma independiente y combinando esas probabilidades con el Teorema de Bayes.

✓ Muy rápido y simple. Sirve como punto de referencia para los otros modelos.

¿Por qué elegimos Naive Bayes?

El único modelo de elección propia — Regresión Logística y Random Forest eran obligatorios en la consigna

1

Nuestras variables son exactamente las que le gustan

Naive Bayes funciona muy bien con variables categóricas binarias. Nuestro modelo usa clima (Tormenta / Lluvia / Despejado), víspera de feriado (Sí / No) y tipo de distancia (larga / corta). Son exactamente ese tipo de datos — categorías con pocas opciones.

2

Sirve como termómetro del pipeline

Si los modelos más complejos (Random Forest y Regresión Logística) no le ganan claramente a Naive Bayes, es una señal de alarma: algo está mal con los datos o las variables. Incluirlo nos da esa referencia honesta.

3

Fácil de explicar

Naive Bayes hace algo intuitivo: calcula qué tan probable es la demora mirando cada variable por separado. Eso es más fácil de explicar al área de negocio que un bosque de 100 árboles de decisión.



Limitación conocida: asume que las variables son independientes entre sí, lo que no siempre es real — por eso fue descartado como modelo final.



Comparación de los 3 Modelos

Cross Validation $k=10$ · Stratified · Evaluados en clase 1 (demorado)

Regresión Logística

AUC	0.662
CA	0.592
F1	0.561
Precision	0.450
Recall	0.747
MCC	0.247

GANADOR — Mayor Recall

Random Forest

AUC	0.660
CA	0.592
F1	0.561
Precision	0.450
Recall	0.746
MCC	0.246

Naive Bayes

AUC	0.659
CA	0.682
F1	0.329
Precision	0.630
Recall	0.223
MCC	0.222



Modelo Ganador: Regresión Logística

Recall = 0.747 · Detecta el 74,7% de los retrasos

Confusion Matrix

Predicted →	Pred: 0	Pred: 1	Σ
Actual: 0	771	715	1486
Actual: 1	218	582	800
Σ	989	1297	2286

 Predicción correcta

 Falso Positivo

 Falso Negativo (costoso)

✓ 582 de 800 retrasos detectados

El modelo detecta correctamente aproximadamente 3 de cada 4 retrasos antes de que ocurran.

⚠ 715 falsas alarmas (FP)

48,1% de los enviados a tiempo reciben alerta. Es el costo asumido para minimizar el error más costoso (FN = 218 casos sin aviso).

Variables Más Importantes

Nomogram — Regresión Logística configurado para clase 1 (retraso)

clima_despacho = Tormenta



Mayor impacto positivo (+retraso)

es_vispera_feriado = Sí



Segundo predictor más fuerte

Tipo distancia = 1



Distancia larga aumenta el riesgo

es_vispera_feriado = No



Efecto protector (reduce riesgo)

clima_despacho = Lluvia



Efecto mínimo (similar a despejado)

Tipo distancia = 0



Distancia corta reduce el riesgo

Conclusion: los factores externos y temporales (tormenta + vispera de feriado) son los principales determinantes, por encima de las características físicas del paquete.



Conclusiones y Recomendaciones

1

Revisión focalizada de envíos

Separar automáticamente envíos con predicción = 1 para flujo de seguimiento activo. Reduce revisión manual del 100% a una fracción.

2

Intervención preventiva

Derivar envíos predecidos como demorados a proveedor prioritario o ruta alternativa en el momento del despacho, antes de que el retraso ocurra.

3

Comunicación proactiva al cliente

Activar notificación automática para entrega_demorada = 1 → transforma un problema reactivo en gestión proactiva.

Hallazgo sorprendente → distancia_km como variable continua era poco significativa, pero categorizada en 'Tipo Distancia' se convirtió en la 3.ª variable más predictora del modelo.



¡Muchas gracias!

Grupo Data Rose

Valentina Montechi, Pilar Ospital, Emilia Rizzato, Felicitas Lacentre y Chiara Behar